

# Употреба неуронске мреже у класификацији слика

Љубић Јанко SW-38/2016  
Факултет Техничких Наука у Новом Саду

## Увод

Улазни подаци састоје се од 320 различитих фотографија цвећа. Укупно се појављује 5 различитих типова цвета а сваки тип, заједно са називом слике на којој се налази описан је у улазном документу који садржи исправне информације о називу сваког цвета на свакој слици. Овај скуп података се користи за тренинг класификатора.

Тест скуп података састоји се од 80 различитих фотографија цветова из истих оних 5 различитих типова. Такође уз тест директоријум са сликама налази се и тест документ са информацијама о називу сваког цвета на свакој тест слици.

Тренинг скуп и тест скуп су међусобно дисјунктни.



## Методологија рада

На почетку су подаци учитани на начин који је обезбедио правилан и паралелан поредак назива цветова са одговарајућим фотографијама из тренинг скупа. То је учињено тако што су потребни подаци прво читани из 'csv' датотеке и коришћени да се паралелно пронађе фотографија са датим називом и назив њеног цвета (односно лабела) и да се паралелно похране у одговарајућу колекцију података.

На идентичан начин на почетку програма учитани су и тест подаци. Како су прочитане фотографије? Свака од фотографија има своју независну резолуцију, било је од користи скалирати их на подједнаку резолуцију што је и учињено и након читања резолуција похрањених фотографија износи **100X 100**. Када говоримо о карактеристикама и посебности сваког цвета морамо узети у обзир и његову боју, из тог разлога слике су учитане у боји, 'RGB'.

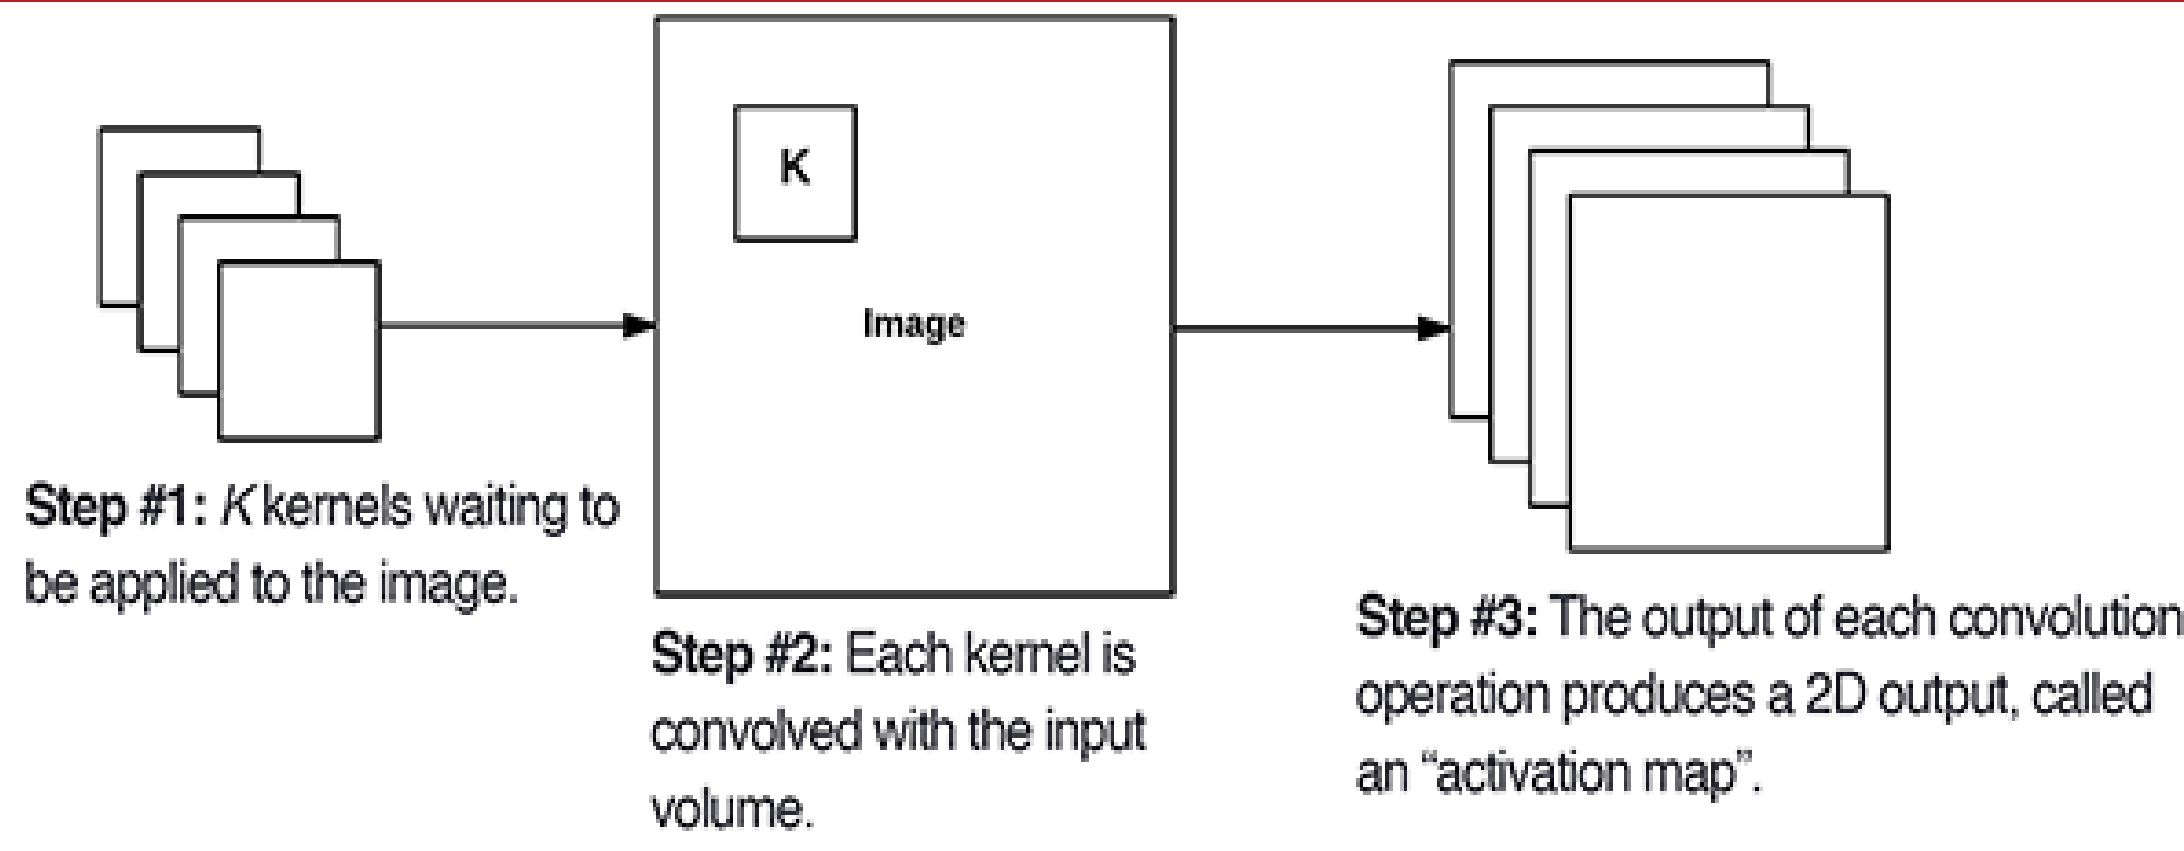
Било је потребно направити модел неуронске мреже и у њега убацити слојеве који ће прочитане податке обрађивати.

За издвајање карактеристика задужен је конволуциони слој **CONV2D** који применом одређеног броја (K) филтера матрице фотографија пресликава у активационе мапе које на себи имају израженије карактеристике (вертикална ивица, хоризонтална ивица, кругови, сенка...).


## Методологија рада

Након овог слоја примењује се нелинеарна активациона функција 'ReLU'. Да бисмо од излаза могли извући неке закључке потребно је да их скалирамо и задржимо најважније карактеристике одбацујући оне небитне заостале од претходних слојева, за то се користи слој под именом 'Max Pooling'.

Након три итерације са комбиновањем горенаведених слојева улазимо у 'Fully connected' слој који „изравна“ излазе из претходних слојева и претвори их у јединствени вектор.



## Шематски приказ протока фотографије кроз неуронску мрежу од улаза до излаза



## Резултати

Након што се мрежа истренира, на њу се може применити тестирање уз помоћ 80 фотографија из тест скупа и упоредити излаз мреже са исправним именима сваког од 80 цветова.

Резултат тог поређења изражава се у проценту тачности. Неуронска мрежа коришћена у овом решењу није конзистентна у оцени решења. Најбољи резултат који постиже је 86,25%. То значи да од 80 фотографија она исправно препознаје 69, односно да греша у 15.75% случајева, код 11 цветова.

У поређењу са решењем направљеним користећи 'HOG DESCRIPTOR' неуронска мрежа је доста успешнија јер је у просеку 20% тачнија.

## Закључак

Неуронска мрежа представља најбоље решење за класификацију слика када је у питању више различитих класа ентитета на фотографијама.

Конкретно решење које користи 'HOG DESCRIPTOR' може бити коришћено уколико радимо са на пример 2 ентитета.

Неуронска мрежа је повољна за мноштво комбинација јер се распоред слојева у њој може мењати и тиме у многоме варирати понашање читавог скупа.

Тренинг скуп у овом случају није био довољно обиман јер скуп од 320 фотографија већ у 13. епохи доводи до прецизности тренинга од 100% и једино решење за то у овом тренутку јесте повећање тренинг скупа података.